Decision Tree - Titanic DataBase

Vinicius Capozzi

Nesse arquivo, veremos um exemplo de como uma decision tree(árvore de desição) consegue identificar padrões com base nas observações da base de treino e assim classificar quais pessoas sobreviveram ou não.

Vamos trabalhar com a base titanic, que contém as seguintes variáveis e características:

```
load("C:/Users/Vinicius/Desktop/MBA/Outros Modelos de Machine Learning/.RData")
titanic %>% head
```

```
##   Survived Pclass    Sex      Age SibSp Parch    Fare Embarked
## 1        N      3   male 22.00000     1     0  7.2500        S
## 2        Y      1 female 38.00000     1     0 71.2833        C
## 3        Y      3 female 26.00000     0     0  7.9250        S
## 4        Y      1 female 35.00000     1     0 53.1000        S
## 5        N      3   male 35.00000     0     0  8.0500        S
## 6        N      3   male 29.69912     0     0  8.4583        Q
```

```
titanic %>% str
```

```
## 'data.frame':    891 obs. of  8 variables:
##  $ Survived: Factor w/ 2 levels "N","Y": 1 2 2 2 1 1 1 1 2 2 ...
##  $ Pclass  : int  3 1 3 1 3 3 1 3 3 2 ...
##  $ Sex     : Factor w/ 2 levels "female","male": 2 1 1 1 2 2 2 2 1 1 ...
##  $ Age     : num  22 38 26 35 35 ...
##  $ SibSp   : int  1 1 0 1 0 0 0 3 0 1 ...
##  $ Parch   : int  0 0 0 0 0 0 0 1 2 0 ...
##  $ Fare    : num  7.25 71.28 7.92 53.1 8.05 ...
##  $ Embarked: Factor w/ 3 levels "C","Q","S": 3 1 3 3 3 2 3 3 3 1 ...
```

Com a função summary, vemos algumas estatíscas descritivas da nossa base de dados que podem nos ajudar a entender melhor como as observações estão distribuídas.

```
summary(titanic)
```

```
##  Survived     Pclass          Sex           Age            SibSp
##  N:549    Min.   :1.000   female:314   Min.   : 0.42   Min.   :0.000
##  Y:342    1st Qu.:2.000   male  :577   1st Qu.:22.00   1st Qu.:0.000
##           Median :3.000                Median :29.70   Median :0.000
##           Mean   :2.309                Mean   :29.70   Mean   :0.523
```

```
##           3rd Qu.:3.000                3rd Qu.:35.00   3rd Qu.:1.000
##           Max.   :3.000                Max.   :80.00   Max.   :8.000
##      Parch            Fare        Embarked
##  Min.   :0.0000   Min.   :  0.00   C:168
##  1st Qu.:0.0000   1st Qu.:  7.91   Q: 77
##  Median :0.0000   Median : 14.45   S:646
##  Mean   :0.3816   Mean   : 32.20
##  3rd Qu.:0.0000   3rd Qu.: 31.00
##  Max.   :6.0000   Max.   :512.33
```

Em seguida, plotaremos alguns gráficos que irão nos dar uma visão melhor sobre as variáveis da nossa base de dados. As variáveis que achei mais interessante destacar foram Sexo, Idade e o número da Classe do passageiro.

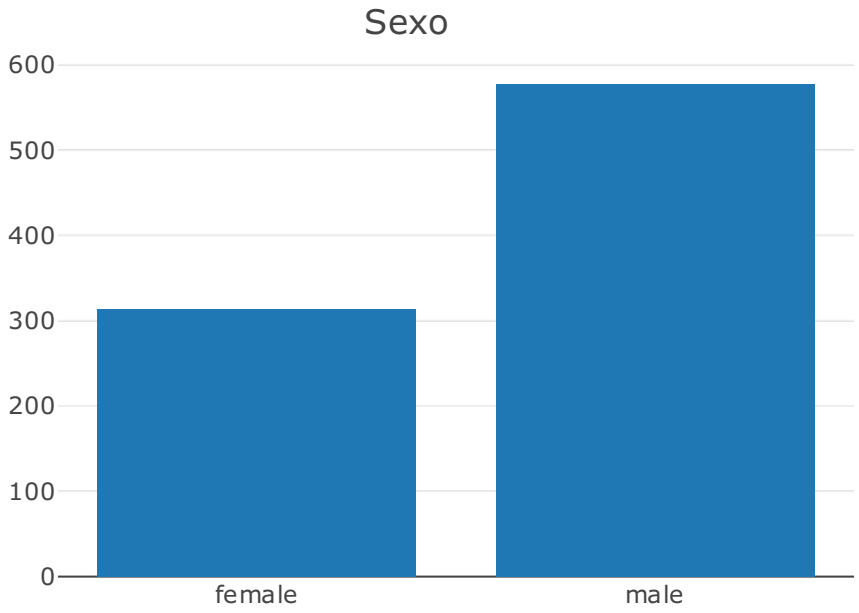

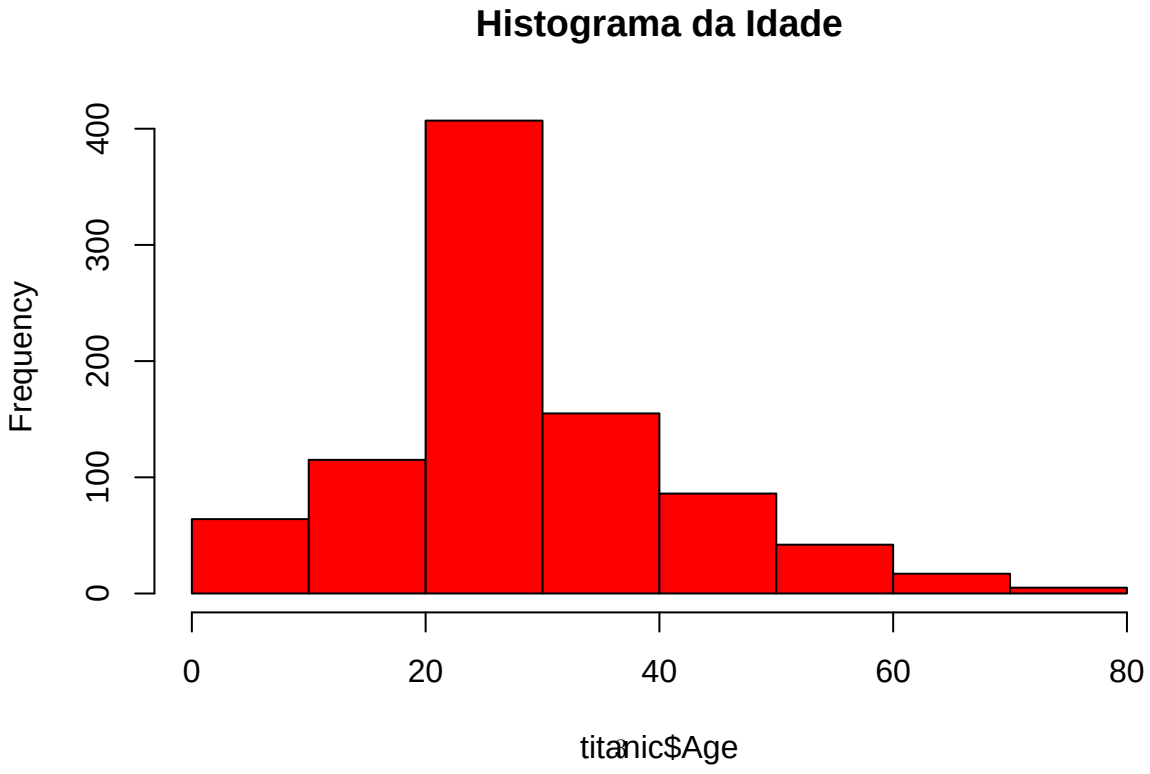

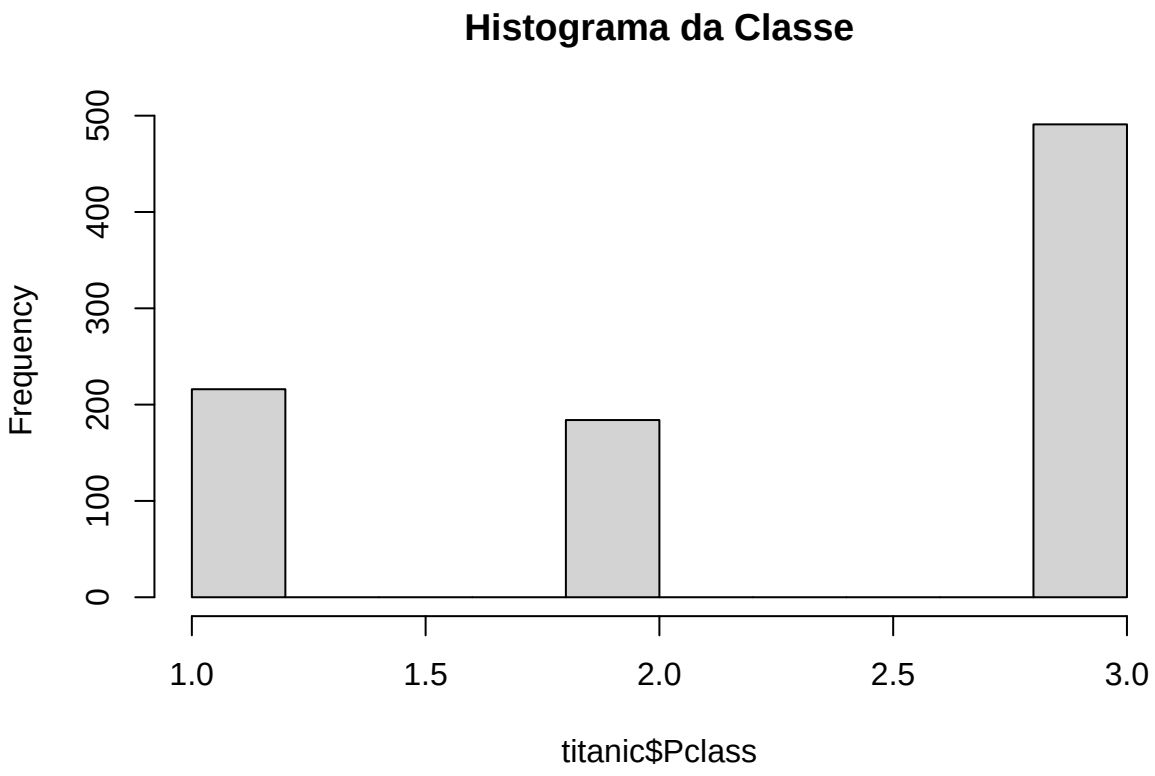

Com a análise exploratória realizada, podemos começar a trabalhar com a construção de algoritmo.Primeiramente, separamos a base de dados em teste e treino para que possamos ver se o nosso modelo está conseguindo classificar corretamente as observações.Depois geramos a variável "arvore" que irá conter a nossa árvore de decisão. Com base no primeiro argumento que passamos na função, no caso se a pessoa é uma sobrevivente ou não, o algoritmo irá testar qual das outras variáveis melhor se relaciona com o fato da pessoa ter sobrevivido, como o sexo, a idade, a classe.

Depois, plotamos a árvore par ver o resultado que ela apresentou.

```
set.seed(123)
bool_treino <- stats::runif(dim(titanic)[1])>.25

treino <- titanic[bool_treino,]
teste  <- titanic[!bool_treino,]
set.seed(123)
arvore <- rpart(Survived ~ Pclass + Sex + Age + SibSp + Parch + Fare + Embarked,
                data=treino,
                parms = list(split = 'gini'),
                method='class'
)
rpart.plot::rpart.plot(arvore
                       )
```

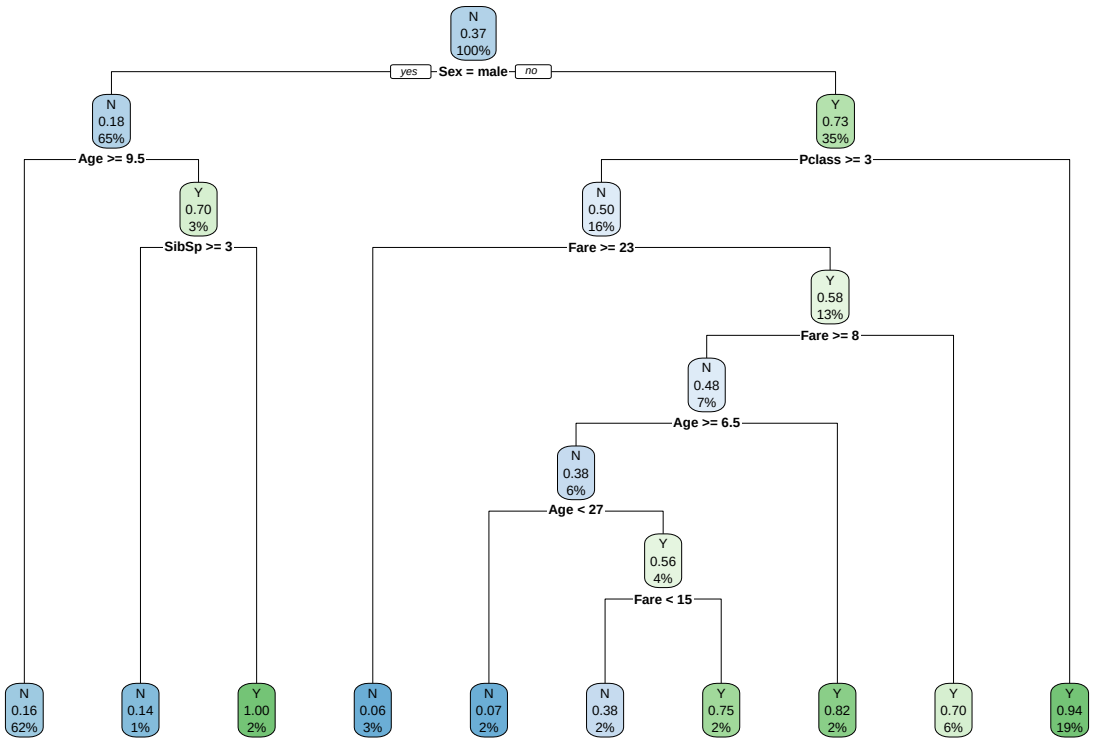


```
p_treino = stats::predict(arvore, treino)
c_treino = base::factor(ifelse(p_treino[,2]>.5, "Y", "N"))
p_teste = stats::predict(arvore, teste)
c_teste = base::factor(ifelse(p_teste[,2]>.5, "Y", "N"))

tab <- table(c_treino, treino$Survived)
acc <- (tab[1,1]+tab[2,2])/nrow(treino)
sprintf('Acurácia na base de treino: %s ', percent(acc))
```

```
## [1] "Acurácia na base de treino: 85% "
```

```
tab <- table(c_teste, teste$Survived)
acc <- (tab[1,1]+tab[2,2])/nrow(teste)
sprintf('Acurácia na base de teste: %s ', percent(acc))
```

```
## [1] "Acurácia na base de teste: 83% "
```

Com o modelo criado, podemos verificar a acurácia(pnúmero de acertos / número de tentativas) que o modelo possui de diversas maneiras. Iremos assumir que se a observação foi classificada com uma chance maior de 50% de sobreviver a pessoa será um sobrevivente, e caso seja menor de 50% a pessoa não será um sobrevivente.

```
prob = predict(arvore, titanic)
class = prob[,2]>.5
tab <- table(class, titanic$Survived)
tab
```

```
##
## class     N   Y
##   FALSE 519 107
##   TRUE   30 235
```

```
df <- as.data.frame(prob)
survived <- filter(df, Y>0.5)
not_survived <- filter(df, Y<0.5)
acc <- (tab[1,1] + tab[2,2])/ sum(tab)
print(paste0('O modelo apresentou ',  nrow(survived) ,' sobreviventes'))
```

```
## [1] "O modelo apresentou 265 sobreviventes"
```

```
print(paste0('O modelo apresentou ',  nrow(not_survived) ,' não sobreviventes'))
```

```
## [1] "O modelo apresentou 626 não sobreviventes"
```

```
print(paste0('A acurácia foi de:', acc))
```

```
## [1] "A acurácia foi de:0.846240179573513"
```

Também vemos no histograma abaixo a quantidade de acertos representados pela barra "true" e a quantidade de erros representada pela barra "false"

```
df5 <- as.data.frame(p_teste)
comp <- data.frame(df5)
comp['verif'] <- teste$Survived
comp$Y[comp$Y >= 0.5] <- 'Y'
comp$Y[comp$Y <= 0.5] <- 'N'
comp['acertos'] <- comp$Y == comp$verif
graf6 <- plot_ly(x=comp$acertos, type = 'histogram') %>% layout(title = 'Acurácia do Modelo')
graf6
```

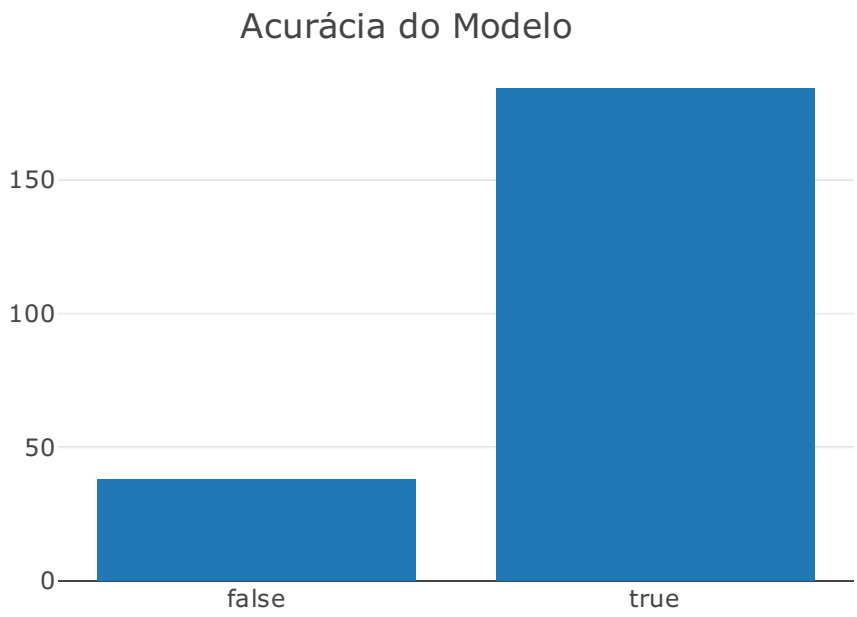

Desse modo, concluimos a construção do algoritmo que é capaz de classificar futuras observações, nos dando a probabilidade de sobrevivência de determinado indivíduo com base nas suas características.